TRABAJO

Título: Trabajo XML – Yahoo Answers

Autor: Alberto Lillo García y Manuel Caballero Bonilla

Asignatura: Bases de Datos Avanzadas.

Fecha: Marzo de 2026.

UCLM
UNIVERSIDAD DE CASTILLA-LA MANCHA

esi Escuela Superior de Informática

ÍNDICE

1. NOTA 6

2. INTRODUCCIÓN 6

3. INVESTIGACIÓN INICIAL: DATASET YAHOO ASNWERS 6

3.1 Exploración del Dataset 6

3.2 Selección de Categorías 7

3.3 Configuración del Entorno 7

3.4 Decisiones Tomadas y Justificación 7

3.5 Posibles Desviaciones y Cómo se Gestionaron 7

4. EXTRACCIÓN DE CATEGORÍAS 8

4.1 Desarrollo del Script de Extracción 8

4.2 Resultados de la Extracción 8

4.3 División en Archivos por Categoría 8

4.4 Posibles Desviaciones y Cómo se Gestionaron 9

5. BASE DE DATOS DOCUMENTAL 9

5.1 Instalación y Configuración de BaseX. 9

5.2 Estrategia de Carga y Resultados 10

5.3 Posibles Desviaciones y Cómo se Gestionaron 10

6. PRIMERA IMPLEMENTACIÓN Y REVISIÓN 10

6.1 Inspección Visual con EmEditor 10

6.2 Verificación Cuantitativa con XQuery 10

6.2.1 Bloque 1 - Verificación General 11

6.2.2 Bloque 2 - Verificación de Campos Supuestamente Obligatorios 11

6.2.3 Bloque 3 - Verificación de Campos Opcionales 11

6.2.4 Bloque 4 - Verificación de Tipos y Formatos 12

6.2.5 Bloque 5 - Análisis de nbestanswers 12

6.2.6 Bloque 6 - Campos Presentes pero Vacíos 12

6.3 Conclusiones de la Verificación 12

6.4 Posibles Desviaciones y Cómo se Gestionaron 12

7. CONSTRUCCIÓN DEL ESQUEMA XSD 13

7.1 Decisión de Diseño: Un único XSD Para Todos los Archivos 13

7.2 XSD Original 13

7.3 XSD Propuesto 14

7.4 Posibles Desviaciones y Cómo se Gestionaron 14

8. DESARROLLO DEL XSLT 15

8.1 Generación del XML de Muestra 15

8.2 Diseño y Estructura del XSLT 15

8.3 Decisiones Técnicas Relevantes 16

8.4 Aplicación del XSLT y Resultado 16
8.5 Posibles Desviaciones y Cómo se Gestionaron 17
9. CONSULTAS, ANÁLISIS Y VISUALIZACIÓN (RESULTADOS) 17
9.1 Bloque 1 - Estadísticas Generales del Corpus 17
9.2 Bloque 2 - Análisis de Redes Sociales 20
9.3 Bloque 3 - Análisis Cross Categoría 23
9.4 Bloque 4 – Calidad de Datos 25
9.5 Bloque 5 – Análisis Temporal 27
10. CONCLUSIONES 30
11. BIBLIOGRAFÍA 30

1. NOTA

Todos los grandes detalles se pueden encontrar en el repositorio de nuestro proyecto.

2. INTRODUCCIÓN

El presente documento recoge la documentación técnica del proyecto práctico realizado por Alberto Lillo García y Manuel Caballero Bonilla correspondiente al bloque de procesamiento de datos *XML* dentro de la asignatura Bases de Datos Avanzadas.

El objetivo principal del trabajo consiste en aplicar distintas técnicas de gestión y análisis de datos estructurados en formato *XML* utilizando un *dataset* real de gran tamaño. Para ello se empleará un subconjunto del *dataset* de preguntas y respuestas de la plataforma *Yahoo Answers*, concretamente el archivo "*FullOct2007*", que contiene millones de interacciones entre usuarios en forma de preguntas, respuestas y metadatos asociados.

A partir de este conjunto de datos se desarrollarán diferentes tareas relacionadas con el tratamiento de documentos *XML* y bases de datos documentales. Entre ellas se incluyen el filtrado y extracción de información relevante del archivo original, el análisis de su estructura, la definición de esquemas mediante *XSD*, la realización de transformaciones utilizando *XSLT* y la ejecución de consultas sobre los datos almacenados en una base de datos documental.

Debido al gran volumen de datos del *dataset* original, el proyecto se centrará en un subconjunto concreto de categorías temáticas que permitan trabajar con un volumen de datos manejable manteniendo al mismo tiempo suficiente representatividad para realizar análisis significativos.

3. INVESTIGACIÓN INICIAL: DATASET YAHOO ASNWERS

En este apartado nos centramos en la fase inicial del proyecto: seleccionar el subconjunto de datos con el que trabajaríamos, comprender en profundidad la estructura del *dataset* y seleccionar y preparar parte del entorno técnico necesario.

3.1 Exploración del Dataset

Lo primero que hicimos fue estudiar en detalle el *dataset* ***Yahoo! Answers Comprehensive Questions and Answers*** (FullOct2007). Se trata de un corpus público de preguntas y respuestas recopiladas de la plataforma Yahoo! Answers hasta octubre de 2007, disponible en formato *XML*. El archivo principal, ***FullOct2007.xml***, tiene un tamaño de 11,42 GB y contiene un total de 4.483.032 registros de preguntas con sus respuestas asociadas, distribuidas en más de 170 categorías temáticas.

El principal reto de esta fase fue explorar el archivo sin bloquearlo en memoria. Para ello desarrollamos scripts en Python con lectura incremental, lo que nos permitió obtener estadísticas generales sin problemas de rendimiento. El orden de ejecución y el propósito de cada script fue el siguiente:

- **extract_maincats.py:** Lee el *XML* completo línea a línea buscando etiquetas *<maincat>* con expresiones regulares. Almacena los valores únicos en un set y genera el archivo ***FullOct2007.maincats.txt*** con las 178 categorías principales únicas del *dataset*. Es el primer script ejecutado y su salida es necesaria para los siguientes pasos.
- **extract_subcats.py:** Lee el *XML* en *chunks* de 1 MB buscando etiquetas *<subcat>*. Genera el archivo ***FullOct2007.subcats.txt*** con todas las subcategorías únicas del *dataset*. Complementa el script anterior para tener una imagen completa de la jerarquía de categorías.
- **validate_extract.py:** Valida que ***extract_maincats.py*** capturó correctamente las 178 categorías únicas. Escanea el *XML* línea a línea, cuenta las *maincats* encontradas, y compara el resultado con el contenido del archivo ***FullOct2007.maincats.txt***. Confirmó que no faltaba ninguna categoría en el archivo generado.
- **analisis_profundo.py:** Lee los archivos *.txt* generados por los dos primeros scripts (no el *XML* directamente). Filtra las categorías ya tomadas por otros grupos y muestra las subcategorías

relacionadas con los temas educativos, científicos, sociales y artísticos, recomendando combinaciones óptimas. Fue el script clave para la toma de decisiones de selección.

- **analizar_distribucion_general.py:** Procesa el *XML* completo a nivel de bloques *<vespaadd>* para obtener la distribución real de todas las categorías incluyendo sus variantes lingüísticas. Confirma el total de 4.483.032 registros procesados sin error y verifica los conteos de las cuatro categorías seleccionadas con todas sus variantes.

3.2 Selección de Categorías

Tras esta exploración inicial, y con los datos de distribución sobre la mesa, procedimos a seleccionar las cuatro categorías temáticas con las que desarrollaríamos el proyecto. El criterio de selección fue su relación con el ámbito académico, educativo y cultural. Las cuatro categorías elegidas son:

- *Science & Mathematics.*
- *Education & Reference.*
- *Social Science.*
- *Arts & Humanities*

Para cuantificar con precisión el volumen de datos de estas categorías se desarrolló el script ***analizar_categorias.py***, que procesa el *XML* completo a nivel de bloques *<vespaadd>* y cuenta las ocurrencias de las cuatro categorías incluyendo todas sus variantes lingüísticas (inglés, español, francés, portugués, italiano y alemán, con un total de 30 variantes). Los resultados obtenidos fueron:

Categoría	Ocurrencias	Porcentaje
Science & Mathematics	183.354	29,9%
Education & Reference	234.604	38,3%
Social Science	58.207	9,5%
Arts & Humanities	137.080	22,4%
TOTAL	613.245	13,68% del dataset total

Tabla 1: *Recuento de Preguntas por Categoría Seleccionada (analizar_categorias.py).*

Este volumen de 613.245 preguntas representa aproximadamente un 13,68% del *dataset* total (4.483.032 registros), suficientemente representativo para realizar análisis significativos y al mismo tiempo manejable para su procesamiento y almacenamiento en una base de datos documental.

3.3 Configuración del Entorno

La configuración de nuestro entorno utilizado para el trabajo fue el siguiente:

- Python 3.12 con las librerías estándar *re*, *os*, *pathlib*, *time* y *collections* para el procesamiento del *XML*.
- Instalación de *EmEditor* como editor de texto capaz de abrir archivos de gran tamaño sin bloquear el sistema.
- Planificación del *stack* tecnológico: *BaseX* como motor de base de datos documental *XML* para las fases posteriores.

3.4 Decisiones Tomadas y Justificación

La elección de estas cuatro categorías se justifica por su temática académica y cultural, que genera preguntas de contenido más estructurado y conceptual. La diversidad interna de cada categoría (Biología, Física, Química, Historia, Filosofía...) ofrece variedad suficiente para el análisis de redes sociales y de calidad de datos. El volumen total de 613.245 preguntas es manejable para *BaseX* manteniendo representatividad estadística.

3.5 Posibles Desviaciones y Cómo se Gestionaron

La desviación prevista en la planificación era el posible bloqueo del sistema al intentar abrir el archivo de 11,42 GB. Esta situación se previno desde el primer momento optando por scripts Python con lectura incremental por *chunks*. La fase transcurrió sin incidencias.

4. EXTRACCIÓN DE CATEGORÍAS

En este apartado llevamos a cabo la extracción de los datos correspondientes a las cuatro categorías seleccionadas del *XML* de 11,42 GB.

4.1 Desarrollo del Script de Extracción

El objetivo era generar un *XML* filtrado con exclusivamente los registros de las cuatro categorías seleccionadas, manteniendo íntegra la estructura *XML* original de cada registro.

La aproximación técnica adoptada fue la lectura del archivo en *chunks* de 2 MB mediante un buffer deslizante, buscando bloques completos *<vespaadd>...</vespaadd>*. Para cada bloque encontrado se extrae el valor de *<maincat>* y se comprueba si pertenece a alguna de las 30 variantes lingüísticas de las cuatro categorías objetivo. En caso afirmativo el bloque completo se escribe en el archivo de salida.

El script ***extraer_categorias.py*** utiliza exactamente el mismo diccionario de 30 variantes que ***analizar_categorias.py***, por lo que el número de preguntas extraídas coincide con el obtenido en el análisis previo: 613.245. Las principales características del script son:

- Lectura incremental por *chunks* de 2 MB sin cargar el archivo completo en memoria.
- 30 variantes lingüísticas entre las cuatro categorías (inglés, español, francés, portugués, italiano y alemán).
- Generación de un *XML* de salida bien formado con cabecera *XML* y elemento raíz *<yahooAnswers>*.
- Indicador de progreso con porcentaje completado, registros procesados y escritos, y *ETA*.[1]
- Resumen final con desglose por categoría y tamaño del archivo generado.

4.2 Resultados de la Extracción

El proceso se ejecutó satisfactoriamente, completándose en aproximadamente 75 minutos, generando el archivo ***yahoo_4categorias.xml*** de aproximadamente 1,5GB:

Categoría	Preguntas extraídas	Porcentaje
Science & Mathematics	183.354	29,9%
Education & Reference	234.604	38,3%
Social Science	58.207	9,5%
Arts & Humanities	137.080	22,4%
TOTAL	613.245	100%

Tabla 2: *Resultados de la Extracción por Categoría (extraer_categorias.py).*

El resultado de 613.245 preguntas es consistente con el conteo previo de ***analizar_categorias.py,*** ya que ambos scripts utilizan el mismo diccionario de variantes lingüísticas.

4.3 División en Archivos por Categoría

Para facilitar la carga en *BaseX* y evitar problemas de memoria con el archivo único de 1,5 GB, se desarrolló el script ***dividir_por_categoria.py,*** que lee el archivo filtrado y genera cuatro *XML* independientes. Este script se ejecuta en únicamente 5-10 minutos al partir del archivo ya filtrado.

Categoría	Preguntas	Tamaño estimado
yahoo_science.xml	183.354	Aproximadamente 450 MB
yahoo_education.xml	234.604	Aproximadamente 500 MB
yahoo_social.xml	58.207	Aproximadamente 200 MB
yahoo_arts.xml	137.080	Aproximadamente 380 MB

Tabla 3: *Archivos XML Generados por Categoría (dividir_por_categoria.py).*

[1] ***ETA:*** Estimated Time of Arrival (Tiempo Estimado de Llegada) o, en nuestro contexto, Tiempo Estimado de Finalización.

Adicionalmente se desarrolló el script ***extraer_directo_4archivos.py***, el cual realiza extracción y división en un único paso directamente desde el archivo original de más de 11 GB, eliminando la necesidad del archivo intermedio de 1,5 GB. Tiene el mismo tiempo de ejecución (Aproximadamente de 60 a 80 minutos) ya que procesa el mismo volumen de datos.

4.4 Posibles Desviaciones y Cómo se Gestionaron

La desviación prevista era que el proceso de filtrado tardará demasiado o se interrumpiera por falta de memoria. Gracias a la lectura incremental por *chunks* el proceso no requirió en ningún momento cargar el archivo completo en memoria, completándose sin interrupciones en aproximadamente 75 minutos. Aunque el tiempo sea elevado, y probablemente se pueda reducir, no fue un tiempo excesivamente tardío para el tamaño previsto y la lógica que conllevaba el programa.

5. BASE DE DATOS DOCUMENTAL

En este apartado nos centramos en instalar y configurar *BaseX*. Además, realizamos la carga inicial de los cuatro archivos *XML*. Esta fase estaba prevista como fase más tardía en la planificación original, pero decidimos adelantarla por dos razones de peso.

En primer lugar, los archivos filtrados estaban completamente listos. En segundo lugar, y más importante, cargar los datos en *BaseX* antes de hacer la revisión estructural del *dataset* tiene mucho más sentido metodológico: así la revisión se apoya en consultas *XQuery* ejecutadas sobre los 613.245 registros reales, en lugar de limitarse a inspeccionar visualmente con *EmEditor*.

5.1 Instalación y Configuración de BaseX.

BaseX es una base de datos documental *XML* de código abierto con soporte nativo para *XQuery*. Se eligió por ser uno de los motores *XQuery* más rápidos en entornos académicos y profesionales, por su interfaz gráfica que facilita la exploración de nodos, y por su capacidad de crear índices que aceleran significativamente las consultas sobre grandes volúmenes de datos.

Configuración aplicada para la base de datos y carga:

- *Internal XML Parser* activado (más rápido y tolerante a errores que el *parser* Java por defecto).
- *Strip whitespace* activado (reduce el espacio en memoria).
- *Text Index* y *Attribute Index* activados para acelerar las consultas XQuery sobre campos de texto.
- *Skip corrupt files* activado como medida preventiva.

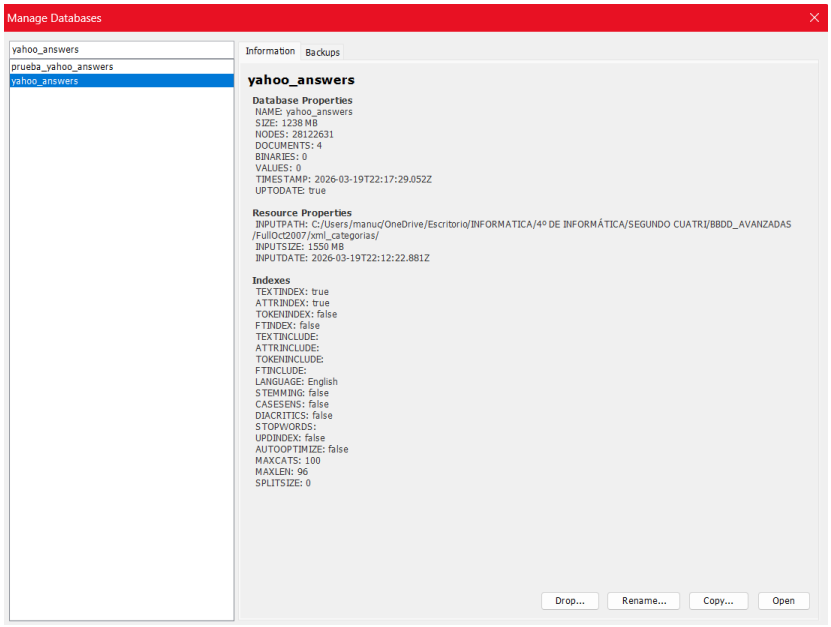

Figura 1: *Prueba de Base de Datos Creada con Configuración Establecida.*

5.2 Estrategia de Carga y Resultados

Antes de cargar los datos intentamos importar el archivo combinado ***yahoo_4categorias.xml*** de 1,5 GB como un único documento. *BaseX* no respondía y terminamos cerrándolo. Aplicamos entonces la estrategia alternativa ya contemplada en la planificación: cargar los cuatro archivos divididos por categoría como documentos independientes dentro de una única base de datos denominada ***yahoo_answers***. Con este enfoque la carga se completó sin problemas.

Para verificar la integridad de la carga ejecutamos inmediatamente la consulta *count(//vespaadd)*, que devolvió exactamente 613.245, confirmando que todos los registros extraídos estaban presentes. El *Query Plan* de *BaseX* mostró además los cuatro documentos correctamente referenciados con sus nodos de inicio correspondientes, lo que validó que la estructura interna era coherente.

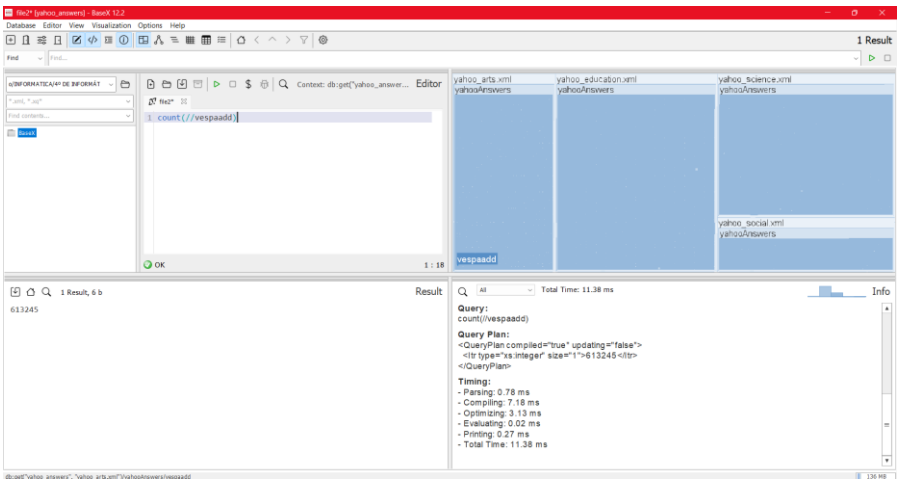

Figura 2: *Base de datos Cargada y Ejecución de Consulta Base.*

5.3 Posibles Desviaciones y Cómo se Gestionaron

El bloqueo de *BaseX* al intentar cargar el archivo único de 1,5 GB era precisamente la desviación prevista en la planificación para esta fase. La solución de dividir la carga en cuatro archivos más pequeños estaba ya contemplada como alternativa, por lo que no fue necesario improvisar nada. La incidencia se resolvió sin retrasos adicionales.

6. PRIMERA IMPLEMENTACIÓN Y REVISIÓN

Posteriormente a la carga de los datos en *BaseX*, realizamos la revisión estructural completa del *dataset*, que constituyó la base para todas las decisiones de diseño del ***XSD***. La metodología fue deliberadamente dual: comenzamos con una inspección visual en *EmEditor* para formarnos una primera impresión de los registros, y después ejecutamos un script de verificación cuantitativa en *BaseX* con consultas *XQuery* organizadas en seis bloques temáticos, cubriendo todos los campos del *dataset* de forma exhaustiva. La combinación de ambas herramientas nos permitió ir más allá de las suposiciones y fundamentar cada decisión en datos reales obtenidos sobre los 613.245 registros.

6.1 Inspección Visual con EmEditor

Abrimos los archivos *XML* filtrados con *EmEditor* y revisamos registros de distintas categorías e idiomas. Esta inspección nos permitió familiarizarnos con la estructura real de los elementos, observar que algunos registros carecían del campo *vot_date* y que otros no tenían el campo *id*. Sin embargo, la limitación de esta aproximación es evidente: *EmEditor* muestra visualmente los archivos, pero no es posible cuantificar la magnitud real de ninguna anomalía ni detectar problemas de formato que aparezcan leyendo manualmente todo el archivo. La inspección visual sirve para orientar la verificación cuantitativa, no para sustituirla.

6.2 Verificación Cuantitativa con XQuery

Desarrollamos un *script XQuery* de verificación estructural, organizado en seis bloques temáticos, que ejecutamos sobre la base de datos ***yahoo_answers*** desde el editor de *BaseX*. El script está diseñado como

una única expresión *let...return* que devuelve todos los resultados en un único *XML* bien estructurado, lo que facilita su lectura e interpretación. A continuación, describimos los hallazgos de cada bloque.

6.2.1 Bloque 1 - Verificación General

El primer bloque confirmó que los 613.245 registros estaban correctamente cargados y que el atributo *type* del elemento *document* contiene únicamente el valor "*wisdom*" en la totalidad del *dataset*, sin ninguna excepción. También obtuvimos los 25 valores distintos del campo *maincat*, que corresponden exactamente a las variantes lingüísticas de las cuatro categorías seleccionadas, confirmando que el filtrado fue correcto.

6.2.2 Bloque 2 - Verificación de Campos Supuestamente Obligatorios

Este bloque fue el más revelador de toda la verificación. La documentación oficial del **WebScope L6-1** marca como *mandatory* los campos de: *uri*, *subject*, *content*, *bestanswer*, *nbestanswers*, *id*, *best_id*, *date* y *lastanswerts*. Sin embargo, los resultados cuantitativos contradijeron varias de estas afirmaciones:

Campo	Ausentes según XQuery	Decisión para el XSD
uri	0	Obligatorio - Confirmado.
subject	0	Obligatorio - Confirmado.
date	0	Obligatorio - Confirmado.
bestanswer	3.857 (0,63% del total)	Anomalía - modelar como opcional.
best_id	3.864 (0,63% del total)	Anomalía - modelar como opcional.
id	38	Anomalía - modelar como opcional.
nbestanswers	1	Anomalía - modelar como opcional.
lastanswerts	1	Anomalía - modelar como opcional.

Tabla 4: *Resultados XQuery sobre Campos supuestamente Obligatorios.*

El hallazgo más significativo fue que ***bestanswer*** y ***best_id*** están ausentes en casi 3.900 registros cada uno. Esto supone una contradicción directa con la documentación oficial y revela un problema real de calidad de datos en el *dataset* original. Si hubiéramos modelado estos campos como obligatorios en el ***XSD***, el esquema habría rechazado el *0,63%* de los registros del *dataset* por una inconsistencia que no es nuestra sino del proveedor. La decisión de modelarlos como opcionales no es una concesión arbitraria sino la consecuencia directa de los datos reales.

6.2.3 Bloque 3 - Verificación de Campos Opcionales

La documentación oficial marca como *optional* los campos de: *content*, *cat*, *maincat*, *subcat*, *qlang*, *qintl*, *language*, *res_date* y *vot_date*. Los resultados cuantitativos aportaron información muy valiosa sobre la frecuencia real de ausencia de cada uno:

Campo	Registros sin el campo	Porcentaje sobre 613.245
content	298.411	48,7%
vot_date	206.652	33,7%
res_date	3.819	0,62%
cat, maincat, subcat	0	0% - todos presentes en el subconjunto filtrado
qlang, qintl, language	0	0% - todos presentes en el subconjunto filtrado

Tabla 5: *Resultados XQuery sobre campos opcionales.*

El resultado más llamativo es que el campo *content*, que contiene el detalle ampliado de la pregunta, está ausente en prácticamente la mitad de los registros del subconjunto (48,7%). Esto significa que casi la mitad de las preguntas de Yahoo! Answers se formulaban únicamente con el título (*subject*), sin añadir ningún detalle adicional. Este dato sería completamente invisible inspeccionando unos pocos registros con *EmEditor*, donde *content* siempre aparecía en los ejemplos revisados.

Los campos *cat*, *maincat*, *subcat*, *qlang*, *qintl* y *language* muestran 0 ausentes en nuestro subconjunto. Esto es perfectamente coherente: filtramos los registros precisamente por el campo *maincat*, por lo que todos los registros extraídos tienen ese campo presente, y los campos de idioma acompañan sistemáticamente a la categoría en el *dataset*.

6.2.4 Bloque 4 - Verificación de Tipos y Formatos

Este bloque verificó que los valores de los campos siguen los formatos que pretendemos modelar en el ***XSD*** propuesto. Los resultados fueron en su mayoría los esperados: *uri* es siempre un entero positivo (0 excepciones), los campos *id* y *best_id* siguen siempre el patrón *u[0-9]+* cuando están presentes (0 excepciones), y los cuatro campos de fechas son siempre enteros no negativos (0 excepciones), lo que confirma el formato Unix *timestamp*.

Sin embargo, se detectó un hallazgo inesperado en *qintl*: el valor "e1" aparece en 4.757 registros, que representa un 0,78% del total. Este valor corresponde a una variante interna de Yahoo! Answers para España que combina letras y dígitos, lo que rompe el estándar *ISO 3166-1 alpha-2* de dos letras. Como consecuencia, el patrón que inicialmente habíamos definido para *RegionCodeType* ([a-z]{2}) debe ampliarse a *[a-z0-9]{2}* para validar correctamente estos registros. El mismo problema se propaga al campo *language*, donde el valor "es-e1" aparece en los mismos 4.757 registros, obligando a ampliar también el patrón de *LanguageRegionType* de *[a-z]{2}-[a-z]{2}* a *[a-z]{2}-[a-z0-9]{2}*. Sin la verificación cuantitativa este error de diseño habría pasado completamente desapercibido.

6.2.5 Bloque 5 - Análisis de nbestanswers

Este bloque caracterizó la distribución de respuestas alternativas dentro del elemento *nbestanswers*. Se confirmó que 1 registro no tiene ningún *answer_item*, lo que valida el ***minOccurs="0"*** en el esquema. Lo más destacable es la enorme variabilidad en el número de respuestas: el máximo observado en un único registro es de 1.422 *answer_item*, mientras que la media por pregunta es de 5,77 respuestas alternativas. Este rango tan amplio es propio de una plataforma de contenido generado por usuarios, donde algunas preguntas de gran interés pueden acumular centenares de respuestas.

6.2.6 Bloque 6 - Campos Presentes pero Vacíos

El último bloque verificó que los campos de texto no contienen valores vacíos cuando están presentes, lo que es relevante para justificar el uso de *NonEmptyStringType* en el ***XSD*** propuesto. El resultado fue 0 en todos los campos comprobados (*subject*, *content*, *bestanswer* y *answer_item*). Ningún campo de texto tiene contenido vacío en el *dataset*, lo que valida la restricción ***minLength="1"*** que introducimos en el esquema mejorado.

6.3 Conclusiones de la Verificación

La verificación cuantitativa con *XQuery* resultó fundamental para tomar decisiones de diseño correctas en el ***XSD***. Los hallazgos más relevantes que modificaron nuestra comprensión inicial del *dataset* fueron:

- La ausencia de *bestanswer* y *best_id* en casi 3.900 registros respectivamente, que contradice la documentación oficial y obliga a modelarlos como opcionales.
- La ausencia de *content* en el 48,7% de los registros, que no era perceptible en la inspección visual.
- La presencia del valor "e1" en *qintl*, que requirió ampliar los patrones de *RegionCodeType* y *LanguageRegionType*.

Sin esta verificación cuantitativa el ***XSD*** habría sido incorrecto en tres puntos distintos.

6.4 Posibles Desviaciones y Cómo se Gestionaron

La desviación prevista para esta fase era encontrar caracteres ilegales o *XML* mal formado que requirieran un proceso de limpieza. No se detectó ninguna irregularidad de este tipo. Los hallazgos inesperados fueron de naturaleza distinta: anomalías de calidad de datos en campos de contenido y un valor no estándar en los códigos de región. Ambas situaciones quedaron documentadas y resueltas en el diseño del ***XSD***, sin necesidad de modificar los datos.

7. CONSTRUCCIÓN DEL ESQUEMA XSD

Con los resultados de la verificación XQuery completamente documentados, construimos los dos esquemas ***XSD*** del proyecto: el ***XSD*** original, que describe fielmente la estructura real del *dataset* sin añadir restricciones que los datos no garantizan, y el ***XSD*** propuesto, que introduce tipos semánticos más precisos y restricciones adicionales justificadas por la verificación cuantitativa.

7.1 Decisión de Diseño: Un único XSD Para Todos los Archivos

La primera decisión fue optar por un único esquema ***XSD*** que valide tanto el archivo combinado ***yahoo_4categorias.xml*** como los cuatro archivos divididos por categoría. La justificación es sencilla: todos los archivos comparten exactamente la misma estructura interna de sus registros. La única diferencia entre el archivo combinado y los archivos divididos es la presencia del atributo *category* en el elemento raíz, que en el ***XSD*** se modela como opcional (*use="optional"*). Crear cuatro esquemas idénticos cambiando únicamente ese atributo no aportaría ningún valor técnico ni documental.

7.2 XSD Original

El criterio de diseño del ***XSD*** original fue describir con fidelidad lo que existe en el *dataset* sin añadir ninguna restricción que los datos no garanticen. Yahoo! Answers era una plataforma de contenido libre sin validación de esquema, lo que explica las anomalías detectadas. Por ello todos los tipos de contenido se modelan como ***xs:string***.

La parte más elaborada del diseño fue determinar la opcionalidad correcta de cada campo, combinando lo que establece la documentación oficial del **WebScope L6-1** con lo que confirman cuantitativamente las consultas XQuery. La tabla siguiente recoge la decisión adoptada para cada campo y la fuente que la justifica:

Campo	Obligatorio / Opcional	Justificación
uri	Obligatorio	0 ausentes en XQuery.
subject	Obligatorio	0 ausentes en XQuery.
date	Obligatorio	0 ausentes en XQuery.
bestanswer	Opcional (anomalía)	3.857 ausentes - XQuery contradice documentación oficial.
best_id	Opcional (anomalía)	3.864 ausentes - XQuery contradice documentación oficial.
id	Opcional (anomalía)	38 ausentes - XQuery contradice documentación oficial.
nbestanswers	Opcional (anomalía)	1 ausente - XQuery contradice documentación oficial.
lastanswerts	Opcional (anomalía)	1 ausente - XQuery contradice documentación oficial.
content	Opcional	298.411 ausentes (48,7%) - documentación oficial y XQuery.
vot_date	Opcional	206.652 ausentes (33,7%) - documentación oficial y XQuery.
res_date	Opcional	3.819 ausentes - documentación oficial y XQuery.
cat, maincat, subcat	Opcional	Doc oficial WebScope L6-1.
qlang, qintl, language	Opcional	Doc oficial WebScope L6-1.

Tabla 6: *Decisiones de Opcionalidad del XSD Original.*

7.3 XSD Propuesto

El ***XSD*** propuesto parte del original y añade un conjunto de mejoras semánticas que hacen el esquema más preciso, más expresivo y útil para la validación real de datos. La característica principal del diseño es que todas las mejoras están respaldadas por los resultados cuantitativos de las consultas *XQuery*: no se añade ninguna restricción que no haya sido previamente verificada sobre los datos reales.

Las mejoras se articulan en torno a siete tipos simples reutilizables, cuya justificación detallada se presenta a continuación:

Tipo	Restricción introducida	Verificación XQuery que lo respalda
UnixTimestampType	xs:nonNegativeInteger	0 valores no numéricos en date, res_date, vot_date y lastanswerts
UserIdType	Patrón u[0-9]+	0 valores de id o best_id fuera del patrón cuando el campo está presente.
DocumentTypeEnum	Enumeración {wisdom}	distinct-values(@type) devuelve únicamente "wisdom" en 613.245 registros.
NonEmptyStringType	minLength="1"	0 campos de texto vacíos en subject, content, bestanswer ni answer_item.
LanguageCodeType	Patrón [a-z]{2}	Los 16 valores distintos de qlang son todos de 2 letras. 0 excepciones.
RegionCodeType	Patrón [a-z0-9]{2}	El valor "e1" en 4.757 registros exige incluir dígitos en el patrón.
LanguageRegionType	Patrón [a-z]{2}-[a-z0-9]{2}	El valor "es-e1" en 4.757 registros exige ampliar la parte de región.

Tabla 7: *Tipos de XSD Propuesto y su verificación con XQuery.*

Además de estos siete tipos, el ***XSD*** propuesto introduce otras mejoras adicionales sobre los elementos y atributos:

- El campo *uri* se tipa como ***xs:positiveInteger*** en lugar de ***xs:string,*** ya que la verificación confirma que es siempre un entero positivo.
- El atributo *type* del elemento *document* se restringe mediante una enumeración al único valor observado ("*wisdom*").
- El atributo *category* del elemento raíz usa una enumeración de los cuatro valores posibles del proyecto (*science*, *education*, *social*, *arts*).
- Todos los tipos complejos y los campos de *DocumentType* incluyen anotaciones ***xs:documentation*** que describen su propósito, el número de ausentes observado y la consulta XQuery que justifica cada decisión.

Esto convierte el ***XSD*** propuesto en un documento autodescriptivo.

7.4 Posibles Desviaciones y Cómo se Gestionaron

La desviación prevista era la dificultad para modelar restricciones complejas o jerarquías. Gracias a la verificación XQuery del día anterior, todas las decisiones de diseño se tomaron con base en datos objetivos. La única corrección inesperada fue la ampliación de los patrones *RegionCodeType* y *LanguageRegionType* por el valor "e1", que sin la consulta de tipos habría producido un ***XSD*** propuesto incorrecto. Esta situación refuerza la decisión metodológica de realizar la verificación cuantitativa antes de construir los esquemas.

8. DESARROLLO DEL XSLT

Ahora bien, desarrollando la hoja de estilos ***XSLT*** del proyecto. El objetivo era transformar una muestra representativa del *dataset* en un documento *HTML* navegable que permitiera visualizar las preguntas y sus respuestas de forma clara y estructurada. La dedicación fue de aproximadamente **4 horas**.

8.1 Generación del XML de Muestra

Antes de construir el ***XSLT*** necesitábamos un archivo *XML* de trabajo manejable. Aplicar la transformación sobre los 613.245 registros completos no tendría mucho sentido para una visualización, por lo que desarrollamos el *script* Python ***generar_muestra_xslt.py,*** que extrae automáticamente 22 preguntas representativas del archivo ***yahoo_4categorias.xml*** siguiendo criterios de diversidad:

- 6 preguntas de *Science & Mathematics.*
- 6 preguntas de *Education & Reference.*
- 4 preguntas de *Social Science.*
- 6 preguntas de *Arts & Humanities.*

Además de la cuota por categoría, el *script* aplica criterios de diversidad cualitativa: favorece preguntas con y sin *vot_date* para mostrar ambos métodos de selección de mejor respuesta, preguntas con muchas respuestas alternativas para demostrar el elemento *details* plegable, y preguntas sin campo *content* para demostrar el manejo de campos opcionales. El resultado fue:

Criterio	Resultado
Total de preguntas	22
Con vot_date (votacion comunitaria)	7
Sin vot_date (elegida por el autor)	15
Sin campo content (elemento ausente en el XML)	2
Idiomas distintos del inglés	0 (dataset predominantemente en-us)

Tabla 8: *Estadísticas de la muestra generada para el XSLT.*

Por último, el *script* aplica una limpieza de entidades *HTML* nominales sustituyéndolas por sus equivalentes numéricos *Unicode*, necesaria porque **Saxon**, el procesador ***XSLT*** interno de *BaseX*, es un *parser XML* estricto que rechaza entidades *HTML* no declaradas. El archivo resultante ***yahoo_muestra.xml*** se cargó en la base de datos ***yahoo_answers*** de *BaseX* como documento adicional.

8.2 Diseño y Estructura del XSLT

La hoja de estilos ***yahoo_answers.xslt*** transforma ***yahoo_muestra.xml*** en un documento *HTML5* con *CSS* embebido. El diseño está pensado para que sea como un *dashboard* interactivo con fondo blanco, tarjetas y una barra de color en la parte superior de cada una de ellas que identifica visualmente la categoría. El *XSLT* se estructura en cuatro *templates* principales:

Template	Funcion
match="/"	Template raiz. Genera la estructura *HTML* completa: cabecera con estadísticas calculadas mediante *XPath*, botones de filtro por categoría, *grid* de tarjetas y *footer*.
match="vespaadd"	*Template* principal. Genera una tarjeta *HTML* por cada registro. Determina la clase de categoría, extrae todos los campos y gestiona los campos opcionales.
name="unix-to-date"	Convierte un Unix *timestamp* a fecha legible (ej: 25 Sep 2005) mediante el algoritmo de Howard Hinnant.
name="flag"	Devuelve el emoji de bandera correspondiente al código de región *qintl*.

Tabla 9: *Templates del XSLT y su función.*

8.3 Decisiones Técnicas Relevantes

Orden de las condiciones xsl:choose para la categoría

- La condición para *Social Science* se comprueba antes que *Science & Mathematic*s porque el valor "*Social Science*" contiene la palabra "*Science*". Si se comprobara *Science* primero, todos los registros de *Social Science* quedarían clasificados incorrectamente. El orden correcto en el ***XSLT*** es: *Social Science, Science & Mathematics, Education, Arts & Humanities* como caso por defecto.

Mostrar el campo content aunque sea idéntico al subject

- El *dataset* Yahoo Answers permite que el campo *content* sea idéntico al *subject* cuando el autor no añade detalle adicional a la pregunta. Una versión anterior del ***XSLT*** suprimía el *content* cuando era igual al *subject* para evitar la repetición. Sin embargo, esto generaba confusión: algunas tarjetas mostraban el campo y otras no, sin que fuera evidente el motivo. La decisión final fue mostrar siempre el *content* cuando existe en el *XML*, aunque sea idéntico al *subject*, respetando fielmente los datos reales. La etiqueta del contador de cabecera se cambió a "*No content fied"* para indicar con precisión que mide los registros donde el elemento *content* está ausente en el *XML* (2 registros), no los que tienen *content* igual al *subject*.

Filtrado interactivo sin JavaScript

- Los filtros de categoría funcionan mediante cuatro *checkboxes* ocultos vinculados a *labels*. El *CSS* usa el selector ***:not(:checked) ~ main .card-{cat}*** para ocultar las tarjetas de las categorías no filtradas. El resultado es un filtrado interactivo completamente funcional sin ninguna línea de JavaScript.

Conversión de fechas Unix timestamp

- *XSLT 1.0* no dispone de funciones de fecha nativas. Se implemento el algoritmo de Howard Hinnant para conversión de días desde *epoch* a fecha gregoriana mediante aritmética entera con ***xsl:variable y floor()***. El resultado convierte, por ejemplo, el valor 1127631600 en "25 Sep 2005".

Entidades HTML en los datos originales

- Los textos de respuestas del *dataset* contienen etiquetas *HTML* escapadas como entidades *XML* (ej: *
*). El ***XSLT*** las muestra como texto literal porque *xsl:value-of* extrae el contenido de texto sin interpretar el *HTML* embebido. Esto es fiel al dato original y documenta una característica real del *dataset*: los campos de texto mezclan texto plano y *HTML* escapado.

8.4 Aplicación del XSLT y Resultado

La transformación se aplicó mediante un *script* Python: ***aplicar_xslt.py***. Este *script* usa la librería ***lxml*** para generar el *HTML* correctamente con la visualización perfecta. Alternativamente desde BaseX con ***xslt:transform-text()*** se puede realizar, pero únicamente se muestra en texto *html*. El archivo *HTML* resultante muestra las 22 preguntas en un *grid* de tarjetas con identificación visual por categoría, fechas legibles, respuestas alternativas plegables y filtros interactivos

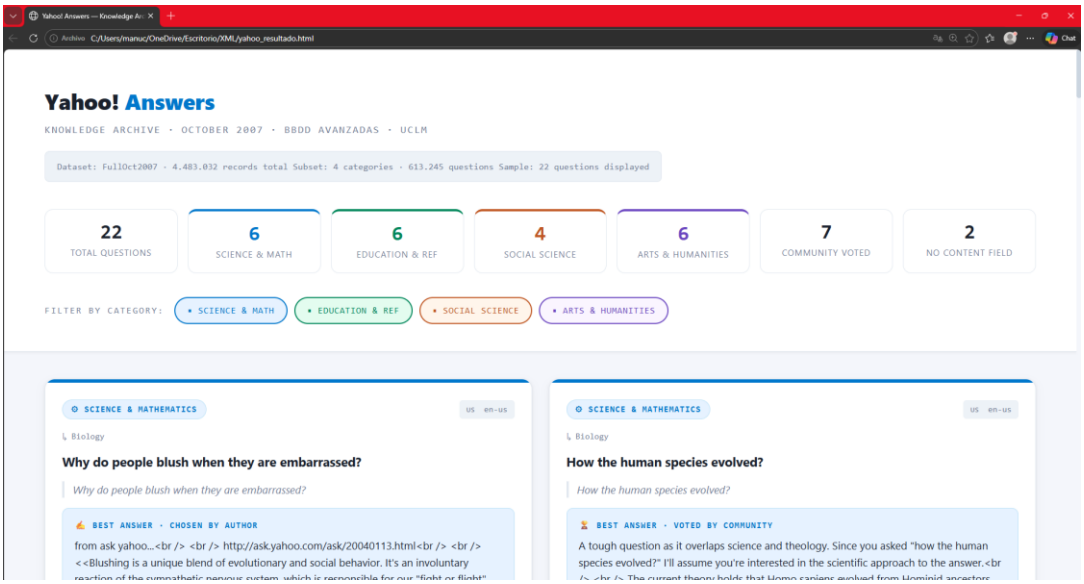

Figura 3: *Resultado de la aplicación de XSLT y aplicar_xslt.py*

8.5 Posibles Desviaciones y Cómo se Gestionaron

Las dificultades técnicas encontradas fueron: elementos *HTML void* sin cierre explicito (meta, input) que Saxon rechazaba, caracteres *Unicode* en comentarios *XML*, entidades *HTML* nominales en los datos, y una clasificación incorrecta de *Social Science* por coincidir con *"Science"*. Todos se resolvieron mediante correcciones puntuales. Adicionalmente se revisó la lógica de visualización del campo *content* para garantizar coherencia entre lo que muestra el *HTML* y lo que cuenta el estadístico de cabecera.

9. CONSULTAS, ANÁLISIS Y VISUALIZACIÓN (RESULTADOS)

Hemos desarrollado 22 consultas XQuery organizadas en cinco bloques temáticos. Cada bloque persigue un objetivo analítico diferenciado: estadísticas descriptivas del corpus, análisis de redes sociales de usuarios, comportamientos entre categorías, calidad de datos y evolución temporal. Las consultas emplean técnicas propias de XQuery 3.1 sobre BaseX 10, combinando acceso por índice de texto (*db:text()*), agrupaciones con *GROUP BY*, expresiones *FLWOR* y la función *subsequence()* para limitar correctamente los resultados. La presentación visual de los resultados se recoge en el *dashboard HTML* generado como entregable complementario, llamado ***yahoo_presentacion.html***; a lo largo de este apartado se indican las figuras correspondientes.

9.1 Bloque 1 - Estadísticas Generales del Corpus

Este primer bloque tiene como objetivo caracterizar cuantitativamente el subconjunto de datos seleccionado. Las cuatro consultas que lo componen (Q1, Q2, Q3, Q4) operan sobre los 613.245 registros *<vespaadd>* almacenados en la base de datos ***yahoo_answers.*** Para maximizar la eficiencia, las variables de categoría (*$sci*, *$edu*, *$soc*, *$art*) se definen una sola vez mediante *db:text()* y se reutilizan en todas las consultas del bloque, evitando recorridos redundantes sobre el árbol *XML*. Se puede consultar más en el archivo ***xquery_bloque1.xq*** del repositorio.

Q1 – Perfil estadístico completo por categoría

Esta consulta calcula, para cada una de las cuatro categorías, seis indicadores en un único barrido: número total de preguntas y porcentaje sobre el subconjunto, subcategorías únicas, registros sin campo *content*, porcentaje de preguntas con *vot_date* (validación comunitaria de la mejor respuesta), y media y máximo de respuestas alternativas (*answer_item*).

CATEGORÍA	TOTAL PREGUNTAS	SIN CAMPO CONTENT	MEDIA RESPUESTAS ALT.	MÁX RESPUESTAS ALT.
Science & Math	183.354	94.589 (51,6%)	5,10	868
Education & Ref	234.604	115.219 (49,1%)	4,73	**1.422**
Social Science	58.207	23.709 (40,7%)	**9,57**	737
Arts & Humanities	137.080	64.894 (47,3%)	6,85	336

Figura 4: *Representación Q1 en yahoo_presentacion.html*

Categoría	Preguntas	%	Subcats	Sin content	Media resp. alt.	Máx resp. alt.
Science & Math	183.354	29,90%	65	94.589 (51,6%)	5,10	868
Education & Ref	234.604	38,26%	103	115.219 (49,1%)	4,73	1.422
Social Science	58.207	9,49%	33	23.709 (40,7%)	9,57	737
Arts & Humanities	137.080	22,35%	54	64.894 (47,3%)	6,85	336

Tabla 10: *Tabla con todos los Resultados de la Consulta.*

Interpretación: Aunque hay muchos datos, los interesantes son los siguientes: *Social Science* genera casi el doble de respuestas alternativas por pregunta (9,57) que *Education* (4,73) (las preguntas de opinión atraen más participación). Y la pregunta con más respuestas de todo el *dataset* pertenece a *Education & Reference*, con **1.422 respuestas** alternativas acumuladas. El campo *content* (descripción extendida de la pregunta) está ausente en aproximadamente la mitad de los registros de todas las categorías; esto no impide el análisis porque la mayor parte del contenido útil está en los campos *subject* y *bestanswer*.

Q2 – Top 15 subcategorías más activas

Esta consulta itera sobre todos los valores distintos del campo *<subcat>* y, para cada uno, contabiliza sus preguntas mediante *db:text()*. El resultado se ordena de forma descendente y se limita a los 15 primeros mediante *subsequence()*. Esta consulta aporta una lectura transversal de los temas más demandados en el subconjunto.

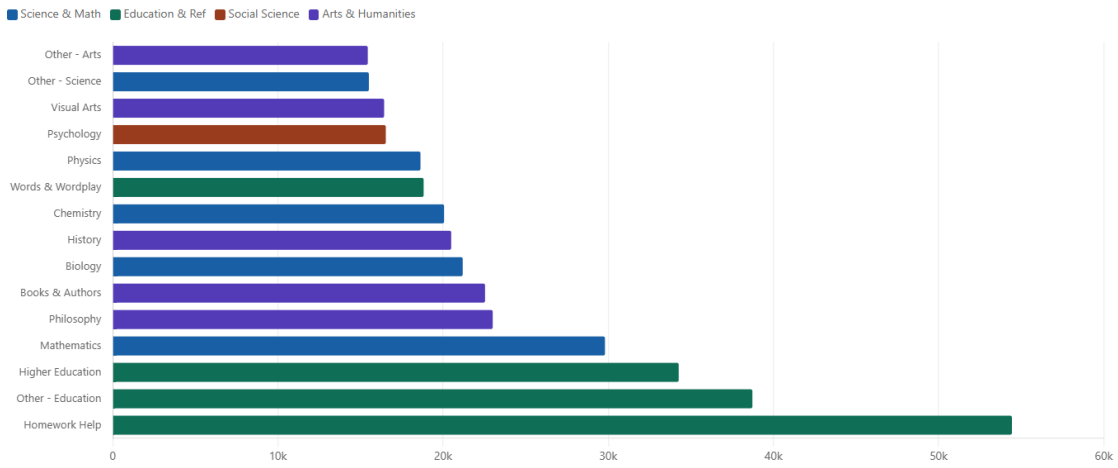

Figura 5: *Representación Q2 en yahoo_presentacion.html*

Interpretación: *Homework Help* acumula 54.439 preguntas, más que cualquier otra subcategoría y casi el doble que la segunda (*Other-Education*, que agrupa preguntas educativas que no encajan en ninguna subcategoría más específica). Las tres primeras posiciones son subcategorías de *Education*, confirmando el uso masivo de Yahoo Answers como herramienta de apoyo escolar. Por otro lado, *Philosophy* (5.ª posición, 23.008 preguntas) supera a *Biology* y *Chemistry*: siendo una subcategoría de *Arts & Humanities* donde las

respuestas no son únicas ni verificables, atrae más participación que las ciencias exactas. *Psychology* es la única subcategoría de *Social Science* en el top 15.

Q3 – Distribución de idiomas, regiones y combinaciones.

Esta consulta agrupa las preguntas por los campos *qlang* (código *ISO* de idioma), *qintl* (código de región/mercado) y *language* (combinación idioma-región), empleando *db:text()* y *distinct-values()* para obtener los valores únicos. El resultado permite caracterizar la distribución geográfico-lingüística del corpus y sirve de base para interpretar los patrones de participación detectados en bloques posteriores.

La representación en el .html creado es únicamente es de *qlang*, sin embargo, la salida se puede conseguir ejecutando el archivo del bloque 1.

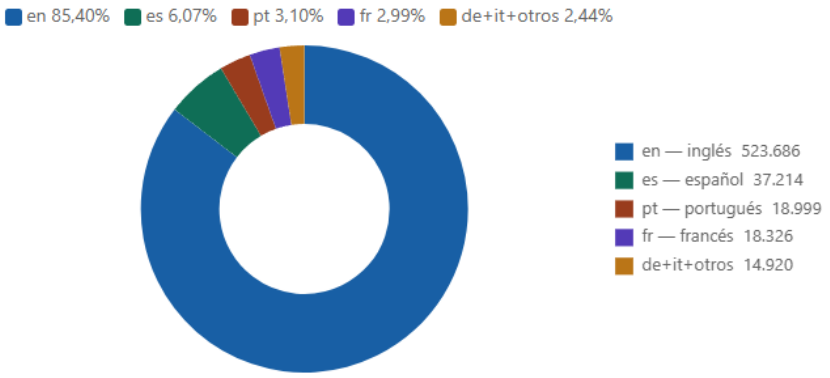

Figura 6: *Representación Distribución Idiomas de Q3 en yahoo_presentación.html – Pestaña Dataset*

La totalidad de los datos conseguidos se ven en las siguientes tres tablas:

Idioma	Preguntas	% del subset
en – inglés	523.686	85,40%
es – español	37.214	6,07%
pt – portugués	18.999	3,10%
fr – francés	18.326	2,99%
de – alemán	7.600	1,24%
it – italiano	7.404	1,21%
Otros (10 códigos)	16	< 0,01%

Tabla 11: *Distribución por idioma (qlang).*

Región	Preguntas	% del subset
us – EE.UU.	476.211	77,65%
uk – Reino Unido	22.684	3,70%
br – Brasil	18.997	3,10%
fr – Francia	18.326	2,99%
in – India	13.630	2,22%
ar – Argentina	11.129	1,81%
mx – México	11.123	1,81%
es – España	10.203	1,66%
de – Alemania	7.597	1,24%
it – Italia	7.401	1,21%
ca – Canadá	5.192	0,85%
e1 – Yahoo interno (español)	4.757	0,78%
Otros	5.986	0,97%

Tabla 12: *Distribución por región (qintl).*

Combinación	Descripción	Preguntas
En – us	Inglés – EE.UU.	476.193
En – uk	Inglés – Reino Unido	22.680
Pt – br	Portugués – Brasil	18.997
Fr – fr	Francés – Francia	18.324
En – in	Inglés – India	13.627
Es – ar	Español – Argentina	11.129
Es – mx	Español – México	11.123
Es – es	Español – España	10.203
De – de	Alemán – Alemania	7.597
It – it	Italiano – Italia	7.401

Tabla 13: *Top 10 combinaciones idioma-región (language).*

<u>Interpretación:</u> El 85,40% de las preguntas son en inglés (campo *qlang* = "*en*"), frente al 77,65% de la región "*us*". La diferencia refleja que el inglés es la lengua dominante también en mercados no

estadounidenses (India, Reino Unido). El español es el segundo idioma (6,07%), distribuido entre Argentina, México, España y el código interno 'e1'. Este código, analizado en detalle en el Bloque 4, es un identificador interno de Yahoo para su portal hispano global que no corresponde a ningún país *ISO* estándar.

Q4 – ¿Quién elige la mejor respuesta? Autor vs comunidad

Esta consulta se basa en la presencia o ausencia del campo *vot_date* que determina quién validó la mejor respuesta: si existe, la comunidad la votó; si no existe, fue el propio autor de la pregunta quien la seleccionó. La consulta calcula esta proporción por categoría reutilizando las variables *$sci*, *$edu*, *$soc*, *$art* ya definidas, sin necesidad de recorrer de nuevo el árbol.

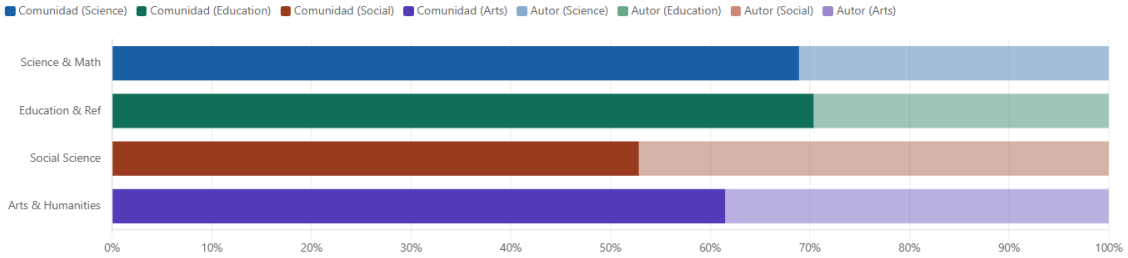

Figura 7: *Representación Q4 en yahoo_presentacion.html*

Interpretación: *Social Science* es la única categoría sin una mayoría comunitaria clara (52,85% comunidad vs 47,15% autor), mientras que en *Education & Reference* la comunidad decide el 70,39% de las veces. La explicación está en la naturaleza de las preguntas: cuando la respuesta es objetiva y verificable (matemáticas, biología, referencia educativa), la comunidad converge fácilmente en la mejor respuesta. Cuando es subjetiva, como ocurre en psicología (subcategoría de *Social Science*) o filosofía (subcategoría de *Arts & Humanities*), el autor prefiere decidir él mismo, ya que no existe una respuesta objetivamente correcta.

9.2 Bloque 2 - Análisis de Redes Sociales

Este bloque modela la plataforma Yahoo! Answers como una red social donde los nodos son los usuarios (identificados por los campos *id* para preguntadores y *best_id* para respondedores) y las aristas representan la relación: este usuario X respondió la pregunta del usuario Y. Las seis consultas se implementan en un único script que aprovecha una sola pasada *GROUP BY* sobre los 613.245 registros de *best_id,* cuyo resultado se almacena en *$resp_grouped* y se reutiliza en Q5, Q7, Q9 y Q10 sin volver a recorrer el árbol. Se puede consultar más en el archivo ***xquery_bloque2.xq*** del repositorio.

Q5 – Top 20 respondedores (por respuestas elegidas como mejor respuesta)

Esta consulta agrupa todos los valores del campo *best_id* mediante *GROUP BY* y ordena los usuarios por número de veces que su respuesta fue seleccionada como la mejor. Se limita a los 20 primeros con *subsequence()*.

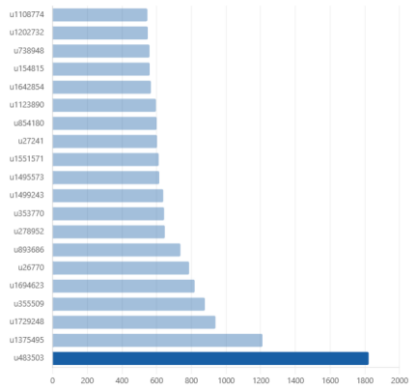

Figura 8: *Representación Q5 en yahoo_presentacion.html*

Interpretación: ***u483503*** lidera con 1.822 respuestas elegidas, un 50% más que el segundo clasificado (***u1375495***, 1.210). Esta brecha tan pronunciada es habitual en plataformas de conocimiento colaborativo: un pequeño grupo de usuarios hiperactivos concentra la mayor parte de las respuestas aceptadas, mientras la inmensa mayoría contribuye ocasionalmente.

Q6 – Top 20 preguntadores (por número de preguntas formuladas)

Análoga a ***Q5*** pero sobre el campo *id* (autor de la pregunta). Permite identificar los usuarios más activos en el rol de preguntador y comparar si existe solapamiento con los grandes respondedores.

Posición	Usuario	Preguntas formuladas	Posición	Usuario	Preguntas formuladas
1	u1452408	799	**11**	u1560955	176
2	u1665729	351	**12**	u617987	176
3	u601894	334	**13**	u1650655	176
4	u1646862	280	**14**	u794546	170
5	u145233	269	**15**	u15394	166
6	u1829265	226	**16**	u445621	161
7	u1116778	195	**17**	u1748900	158
8	u150548	189	**18**	u962461	153
9	u1649597	188	**19**	u26770	148
10	u449978	178	**20**	u1572994	148

Tabla 14: *Q6 – Top 20 Preguntadores.*

Interpretación: ***u1452408*** formula 799 preguntas, más del doble que el segundo (***u1665729***, 351). El único usuario que aparece en ambos top 20 es ***u26770*** (posición 6 en respondedores con 787 respuestas elegidas, posición 19 en preguntadores con 148 preguntas). Esta rareza se analiza formalmente en Q7.

Q7 – Usuarios bidireccionales (top 200 en ambos roles)

Esta consulta cruza los 200 primeros respondedores con los 200 primeros preguntadores e identifica los usuarios presentes en ambas listas. Para cada usuario bidireccional calcula la actividad total (respuestas + preguntas) y ordena de mayor a menor.

Usuario	Respuestas elegidas	Preguntas formuladas	Actividad total
u26770	787 (posición 6 en top respondedores)	148 (posición 19 en top preguntadores)	935
u449978	395 (posición 40 en top respondedores)	178 (posición 10 en top preguntadores)	573

Tabla 15: *Q7 – Usuarios Bidireccionales.*

Interpretación: Solo 2 usuarios de los 613.245 registros pertenecen simultáneamente al top 200 en ambos roles. Este resultado confirma que los roles de preguntador y respondedor están prácticamente separados: los usuarios que más responden apenas preguntan, y viceversa. ***u26770*** es el caso más notable con 935 interacciones totales y un perfil generalista (responde en las 4 categorías).

Q8 – Pares preguntador-respondedor más frecuentes

Esta consulta agrupa los registros por la dupla (*id*, *best_id*) mediante *GROUP BY* con dos claves, cuenta las ocurrencias y retiene solo los pares con más de una co-aparición. Evidencia relaciones de confianza recurrentes entre usuarios concretos.

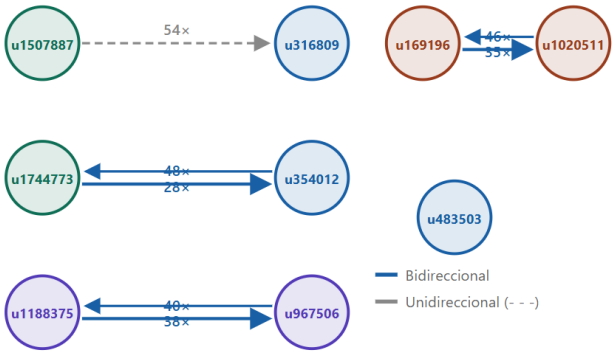

Figura 9: *Representación Q8 en yahoo_presentacion.html*

Preguntador	Respondedor	Veces	Tipo de relación
u1507887	u316809	54	Unidireccional
u1744773	u354012	48	Bidireccional (inverso: 28 veces)
u169196	u1020511	46	Bidireccional (inverso: 35 veces)
u364678	u1477624	42	Unidireccional
u208186	u1277801	40	Unidireccional
u1188375	u967506	40	Bidireccional (inverso: 38 veces)
u296896	u136091	36	Unidireccional
u682529	u1063245	34	Unidireccional

Tabla 16: *Q8 – Pares Preguntador-Respondedor más Frecuente.*

Interpretación: El par más frecuente (***u1507887*** → ***u316809***) aparece 54 veces. El patrón más singular es la relación bidireccional ***u1188375*** ←→ ***u967506*** (40 y 38), una simetría muy alta para un entorno Q&A donde lo habitual es que los roles sean asimétricos. En la visualización del *dashboard* se representa un subconjunto de pares para mantener legibilidad, mientras que la tabla recoge los pares más repetidos del ranking.

Q09 – Categoría dominante de los top 10 respondedores.

En esta consulta para cada uno de los 10 mayores respondedores, desagrega sus mejores respuestas por categoría canónica y permite clasificar perfiles como especialistas o generalistas.

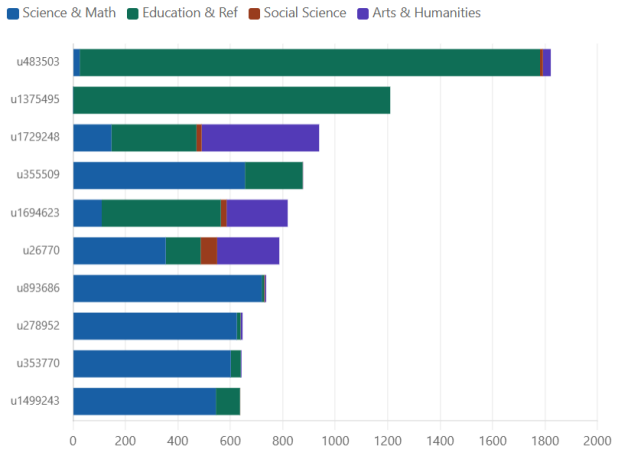

Figura 10: *Representación Q09 en yahoo_representacion.html*

Interpretación: La mayoría de los grandes respondedores se especializan en una sola categoría: ***u893686*** (97,7% en *Science*), ***u1375495*** (99,9% en *Education*), ***u854180*** (100% en *Science*). Sin embargo, hay

excepciones notables: ***u1729248*** y *u1694623* distribuyen sus respuestas de forma más equilibrada entre categorías, demostrando que también es posible ser un respondedor de alto volumen sin especializarse en una única área temática.

Q10 – Generalistas vs. Especialistas (top 50 respondedores)

Esta consulta amplía ***Q9*** al top 50 y clasifica cada usuario según el número de categorías en las que aparece con al menos una mejor respuesta: 1 (especialista puro) hasta 4 (generalista).

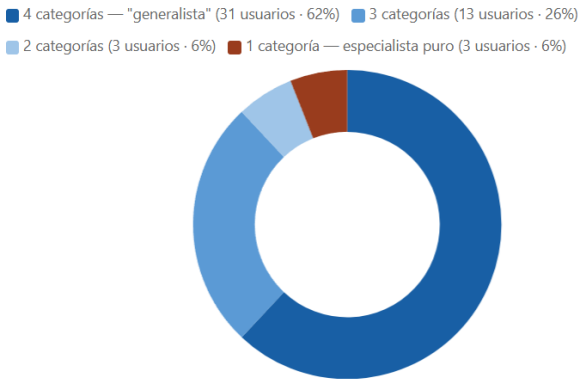

Figura 11: *Representación Q10 en yahoo_representación.html*

Interpretación: El 62% del top 50 aparece como "generalista" (presencia en 4 categorías), pero esto no implica reparto equilibrado: muchos tienen más del 90-99% de sus respuestas en una única categoría y alguna respuesta aislada en las demás. La distinción relevante es entre los 3 especialistas puros (100% en una categoría) y el resto.

9.3 Bloque 3 - Análisis Cross Categoría

Este bloque estudia el comportamiento de los usuarios más activos entre categorías. Las tres consultas exploran en qué medida los respondedores top responden fuera de su dominio habitual y qué subcategorías presentan mayor diversidad de participantes. ***Q11*** emplea los *IDs* y categorías dominantes del top 50 ya obtenidos en ***Q10***, evitando el costoso cálculo doble de *GROUP BY* anidado.

Q11 – Movilidad cross categoría del top 50

En esta consulta para cada usuario del top-50, calcula el porcentaje de mejores respuestas fuera de su categoría dominante y ordena por movilidad.

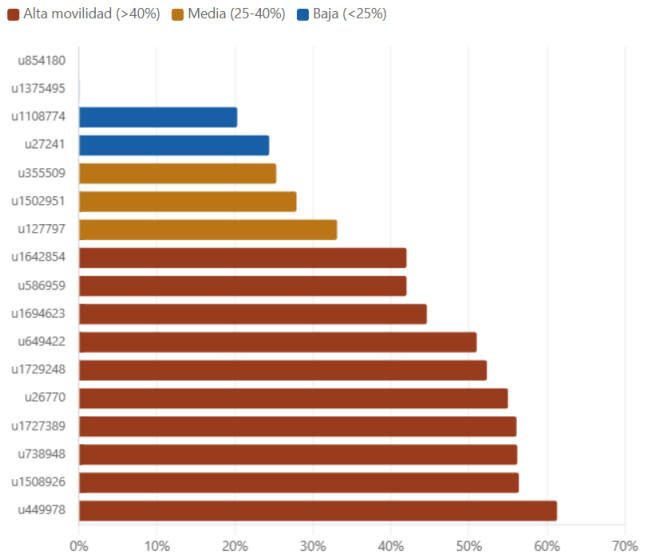

Figura 12: *Representación Q11 en yahoo_representacion.html*

Estadística global	Valor
Total respuestas del top-50	27.938
En categoría dominante	22.343 (79,97%)
Fuera de categoría dominante	5.595 (20,03%)
Mayor movilidad	u449978 - 61,3% fuera de su categoría dominante
Menor movilidad	u854180 - 0,0% (especialista puro)
u1375495 (2.º respondedor global)	0,1% fuera de Education (1 respuesta de 1.210)

Tabla 17: *Q11 – Movilidad Cross Categoría del Top 50 Respondedores.*

Interpretación: El 20,03% de respuestas fuera de la categoría dominante evidencia que la plataforma no es un conjunto de silos estancos: existe una circulación significativa de conocimiento entre áreas. Los especialistas de alto volumen como ***u1375495*** prácticamente nunca salen de su dominio, mientras que los perfiles generalistas como ***u26770*** o ***u1729248*** superan el 50% de movilidad cross categoría.

Q12 – Subcategorías con mayor número de respondedoras únicos

Esta consulta calcula para cada subcategoría con ≥ 500 preguntas el número de respondedores únicos distintos (*distinct-values(best_id)*) y su ratio de diversidad (respondedores únicos / preguntas). Se ordena por número absoluto y se limita al top 15.

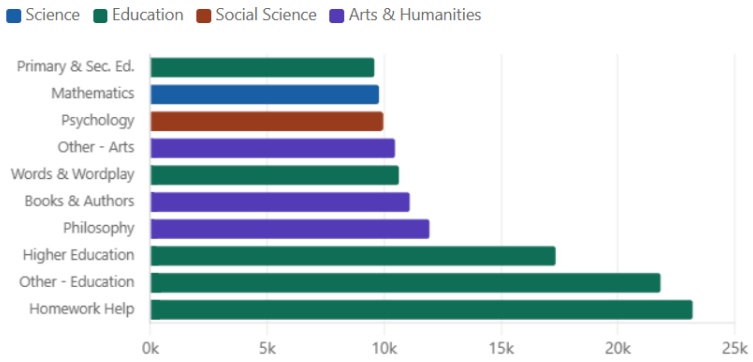

Figura 13: *Representación Q12 en yahoo_representacion.html*

Interpretación: *Homework Help* (*Education*) lidera en volumen absoluto (23.199 respondedores únicos). Pero volumen no implica diversidad proporcional: su ratio respondedores/preguntas es 0,426. Esta métrica absoluta (***Q12***) se complementa con ***Q13***, que ordena por ratio para medir concentración.

Q13 – Subcategorías más democráticas (mayor ratio diversidad)

En esta consulta se mantiene la estructura de ***Q12*** pero ordena por el ratio respondedores únicos/preguntas de mayor a menor. Un ratio cercano a 1,0 indica que, casi para cada pregunta, interviene un respondedor distinto (alta diversidad relativa).

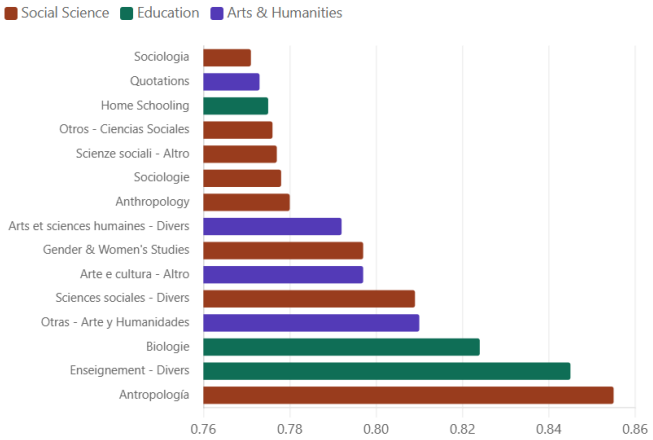

Figura 14: *Representación Q13 en yahoo_representacion.html*

Subcategoría	Categoría	Preguntas	Resp. únicos	Ratio
Antropología	Social Science	544	465	0,855
Enseignement - Divers	Education	516	436	0,845
Biologie	Education	547	451	0,824
Otras - Arte y Humanidades	Arts & Hum.	636	515	0,810
Sciences sociales - Divers	Social Science	791	640	0,809
Arte e cultura - Altro	Arts & Hum.	513	409	0,797
Gender & Women's Studies	Social Science	2603	2074	0,797
Arts et sciences humaines - Divers	Arts & Hum.	612	485	0,792
Anthropology	Social Science	1270	990	0,780
Sociologie	Social Science	676	526	0,778
Scienze sociali - Altro	Social Science	669	520	0,777
Otros - Ciencias Sociales	Social Science	1439	1116	0,776
Home Schooling	Education	1315	1019	0,775
Quotations	Arts & Hum.	4613	3568	0,773

Tabla 18: *Q13 – Subcategorías más democráticas (mayor ratio diversidad)*

Interpretación: ***Q13*** confirma, con el top 15 completo, que volumen y diversidad no son equivalentes. Frente a ***Q12*** (métrica absoluta de respondedores únicos), aquí domina una diversidad proporcional muy alta (0,771-0,855), con fuerte presencia de *Social Science* y *Arts & Humanities* y aportes de *Education*. Esto indica baja concentración: muchas preguntas son respondidas por usuarios distintos. El contraste es claro con subcategorías masivas, pero más concentradas como *Mathematics* (ratio 0,328 en ***Q12***), donde el peso recae en un núcleo más estable de respondedores.

9.4 Bloque 4 – Calidad de Datos

Las cinco consultas de este bloque evalúan la integridad del dataset desde cinco ángulos distintos: anomalías en campos obligatorios, coherencia lógica entre identificadores, coherencia temporal entre marcas de tiempo, posibles datos sintéticos y distribución de un código de región no estándar.

Q14 – Anomalías en campos declarados como obligatorios, por categoría.

Según la documentación oficial del *dataset* ***WebScope L6-1***, los campos *id*, *bestanswer*, *best_id* y *nbestanswers* deberían estar siempre presentes. La consulta cuenta los registros en que cada campo está ausente o vacío, desagregando por categoría. La visualización realizada es la siguiente:

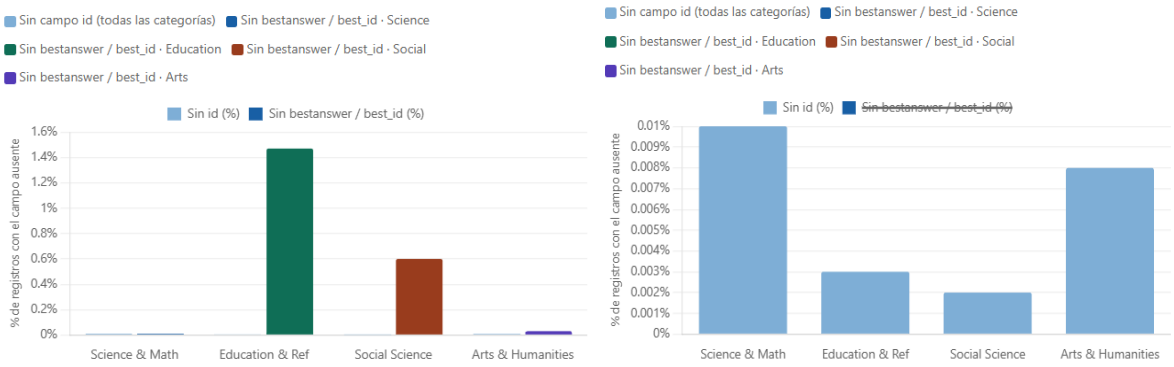

Figura 15: *Representación Interactiva Q14 en yahoo_representacion.html*

El resultado completo de la consulta se puede visualizar en formato tabla a continuación:

Categoría	Total	id ausente	% id	bestanswer ausente	% bestanswer	best_id ausente	% best_id	nbestanswers ausente	% nbestanswers
Science and Mathematics	183.354	18	0.010 %	11	0.01%	20	0.01 %	0	0.000%
Education and Reference	234.604	8	0.003 %	3.454	1.47%	3.453	1.47 %	1	0.000%
Social Science	58.207	1	0.002 %	347	0.60%	347	0.60 %	0	0.000%
Arts and Humanities	137.080	11	0.008 %	45	0.03%	44	0.03 %	0	0.000%

Tabla 19: *Resultados Q14 – Anomalías por Categoría*

Q15 – Respuestas "fantasma" (best_id sin aparición en ningún answer_item)

En esta consulta revisamos las respuestas fantasmas. Una respuesta fantasma es aquella en el que el campo *best_id* está presente, indicando que hay una mejor respuesta identificada, pero el registro no contiene ningún elemento <*answer_item*> en <*nbestanswers*>. Esto implicaría una referencia a una mejor respuesta no materializada en el propio registro.

Resultado	Valor
Total con best_id válido	609.381
Con best_id sin ninguna respuesta alternativa	0 (0,00%)
Valor en categorías	0 en cada una de ellas

Tabla 20*: Resultados Q15 – Respuesta fantasma*

Interpretación: Según los resultados la integridad referencial en todas las categorías es completa.

Q16 – Inconsistencias temporales (res_date anterior a date)

Esta consulta compara los *timestamps Unix* de *date* (publicación) y *res_date* (resolución). Por definición, la resolución no puede ser anterior a la publicación.

Resultado	Valor
Total con ambas fechas válidas	609.426
Con res_date < date	1 (0,0002%)
Categoría del registro afectado	Education & Reference

Tabla 21: *Resultados Q16 – Inconsistencias temporales*

Interpretación: Hay 609.426 registros con ambas fechas presentes; solo 1 es inconsistente (*Education & Reference*) , debido probablemente a un error puntual de la entrada de datos, por lo que para análisis temporales válidos se usan 609.425. Por lo tanto, la tasa de inconsistencia temporal es despreciable.

Q17 – Timestamps idénticos en date y res_date

Esta consulta detecta registros donde *date = res_date* (publicación y resolución en el mismo segundo). Este patrón potencialmente indica datos sintéticos o migración automatizada.

Resultado	Valor
Total con ambas fechas válidas	609.426
Con date = res_date exactamente	0 (0,00%)

Tabla 22: *Resultados Q17 – Timestamps idénticos en date y res_date*

Interpretación: Dado el 0% obtenido como resultado, podemos concluir que no se detectan indicios de datos sintéticos ni migración automatizada.

Q18 – Distribución del código "e1" en el campo qintl

Esta consulta sirve para identificar las distribuciones del código *"e1"*, un código no *ISO* estándar: es un identificador interno que Yahoo Answers empleaba para su portal de español global, distinto de los mercados nacionales ***es*** (España) y ***mx*** (México). Para ello utilizamos el campo *qintl* que almacena el código de región/mercado del usuario siguiendo una convención de dos caracteres alfanuméricos. La existencia de este código requirió ampliar el patrón de validación de *RegionCodeType* en el *XSD* propuesto de ***[a-z]{2}*** a ***[a-z0-9]{2}***.

COMBINACIÓN LANGUAGE	REGISTROS	SIGNIFICADO
es-e1	4.756 (99,98%)	Español con región Yahoo interna
pt-e1	1 (0,02%)	Portugués con región Yahoo interna

Figura 16: *Representación Q18 en yahoo_presentacion.html*

Métrica	Valor
Total registros e1	4.757
% del total	0.78%
es-e1	4.756
pt-e1	1
Science and Mathematics	0
Education and Reference	1.537
Social Science	1.487
Arts and Humanities	1.733

Tabla 23: *Resultados Q18 – Distribución del código "e1"*

Interpretación: Los 4.757 registros con ***qintl = "e1"*** representan el 0,78% del total. El 99,98% de ellos tienen ***language = "es-e1"*** y solo 1 presenta *"pt-e1"*. Están completamente ausentes en *Science & Mathematics* (la categoría con menor participación hispanohablante) y se distribuyen entre *Education* (32%), *Social Science* (31%) y *Arts* (36%), temáticas más demandadas por el público hispanohablante. Esta distribución confirma que *"e1"* es un artefacto del sistema de Yahoo, no un error en los datos.

Resumen de bloque 4:

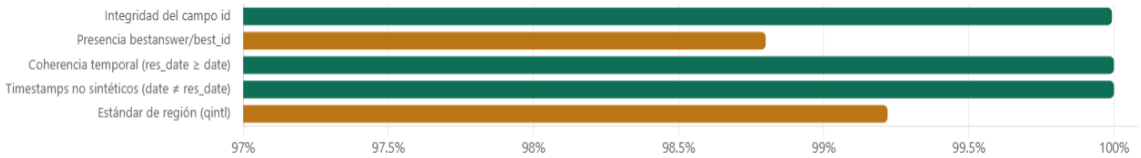

Figura 17: *Representación del resumen del bloque 4.*

9.5 Bloque 5 – Análisis Temporal

Las cuatro consultas de este bloque exploran la dimensión cronológica del corpus. El Bloque 5 se implementó en dos archivos separados para aislar el tratamiento de conversiones numéricas y garantizar tipado correcto en *BaseX* cuando se opera con *timestamps* (forzando conversiones sobre *string* y seleccionando nodos individuales cuando procede).

Q19 – Evolución mensual de preguntas (2005 – 2007)

Esta consulta convierte el *timestamp Unix* del campo date a año y mes mediante aritmética aproximada, agrupa con *GROUP BY* y filtra a 2005-2007. De esta forma el resultado permitirá identificar: fases de crecimiento, discontinuidades de cobertura temporal y meses atípicos (picos o valles).

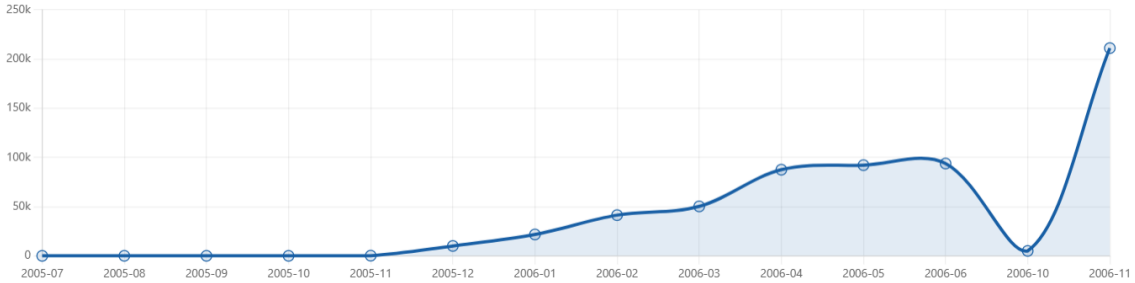

Figura 18: *Representación Q19 en yahoo_presentacion.html*

Año-Mes	Preguntas	Año-Mes	Preguntas
2005-07	1	**2006-01**	21.714
2005-08	37	**2006-02**	41.370
2005-09	30	**2006-03**	50.262
2005-10	14	**2006-04**	87.538
2005-11	176	**2006-05**	92.162
2005-12	10.062	**2006-06**	93.804
(gap)	-	**2006-10**	5.023 (gap)
(gap)	-	**2006-11**	211.052 ← máximo

Tabla 24*: Resultados numéricos Q19 – Evolución mensual de preguntas*

Interpretación: La serie muestra un crecimiento intenso desde finales de 2005 hasta junio de 2006, seguido de una discontinuidad clara (no aparecen julio-septiembre de 2006 en la salida), un valor bajo en octubre y un máximo extraordinario en noviembre de 2006. El hallazgo clave es que la evolución no debe leerse como una curva continua de negocio, sino como una serie con señales de cobertura parcial del extracto temporal. Aun con esa cautela, noviembre de 2006 emerge inequívocamente como el mes de mayor actividad.

Q20 – Mes con mayor actividad global y por categoría

Esta consulta complementa ***Q19*** identificando el pico máximo de actividad tanto a nivel global (dado también por ***Q19***) como para cada categoría individualmente.

Ámbito	Año	Mes	Preguntas
Global	2006	11	211.052
Science and Mathematics	2006	11	61.114
Education and Reference	2006	11	68.053
Social Science	2006	11	34.945
Arts and Humanities	2006	11	46.940

Tabla 25: *Resultados Q20 – Mes con mayor actividad global y por categoría*

Interpretación: El máximo global (noviembre 2006) coincide con el máximo de las cuatro categorías. Esto refuerza el hallazgo de fenómeno transversal: no es una subida localizada en una temática concreta, sino un salto de actividad general del conjunto analizado.

Q21 – Tiempo medio de resolución por categoría

En esta consulta, para cada registro con *res_date* y *date* válidos y coherentes (*res_date* ≥ *date*), calcula la diferencia en días dividiendo la diferencia de *timestamps* entre 86400 segundos. La media se obtiene con *avg()* y se desagrega por categoría

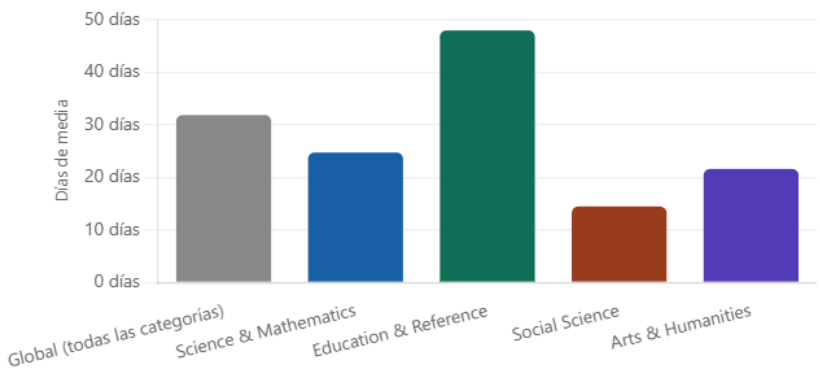

Figura 19: *Representación de Q21 en yahoo_presentacion.html*

Ámbito	Registros válidos	Media (días)
Global	609.425	31,87
Science and Mathematics	183.351	24,73
Education and Reference	231.168	47,98
Social Science	57.862	14,46
Arts and Humanities	137.044	21,61

Tabla 26: *Resultados Q21 – Tiempo medio de resolución por categoría*

Interpretación: *Social Science* se resuelve en 14,46 días de media, las preguntas de opinión reciben respuesta rápida porque muchos usuarios tienen algo que aportar inmediatamente. *Education & Reference* tarda 47,98 días, las preguntas de referencia académica específica pueden esperar semanas hasta que alguien con el conocimiento exacto responde. La media global es de 31,87 días.

Q22 – Distribución por rangos de tiempo de resolución

Esta consulta clasifica cada registro con resolución válida descomponiendo su resolución en cinco tramos (< 1 hora, 1h-24h, 1-7 días, 5-30 días y más de 30 días). Mientras ***Q21*** ofrece una media (resumen), ***Q22*** muestra la forma completa de la distribución y permite detectar concentración en respuestas rápidas o tardías.

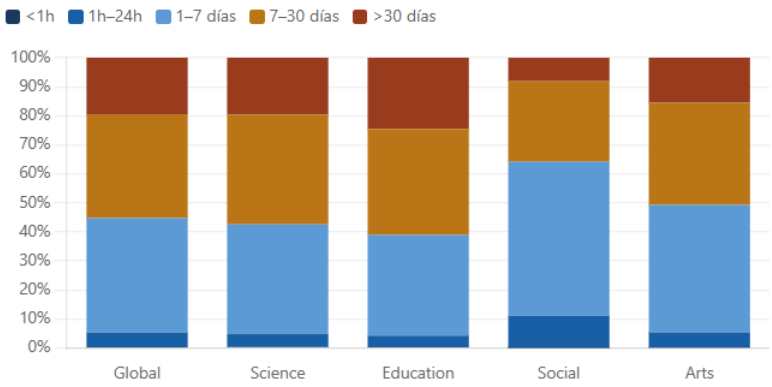

Figura 20: *Representación de Q22 en yahoo_presentacion.html*

Categoría	Total	< 1h	1h-24h	1-7 días	7-30 días	> 30 días
Global	609.425	1.155 (0,19%)	31.016 (5,09%)	240.421 (39,45%)	218.125 (35,79%)	118.708 (19,48%)
Science and Mathematics	183.351	489 (0,27%)	8.194 (4,47%)	69.346 (37,82%)	69.367 (37,83%)	35.955 (19,61%)
Education and Reference	231.168	485 (0,21%)	9.286 (4,02%)	80.146 (34,67%)	84.435 (36,53%)	56.816 (24,58%)
Social Science	57.862	13 (0,02%)	6.384 (11,03%)	30.719 (53,09%)	16.047 (27,73%)	4.699 (8,12%)
Arts and Humanities	137.044	168 (0,12%)	7.152 (5,22%)	60.210 (43,93%)	48.276 (35,23%)	21.238 (15,50%)

Tabla 27: *Resultado completos de Q22 – Distribución por rangos*

Interpretación: El patrón global está centrado en 1-7 días (39,45%) y 7-30 días (35,79%). *Social Science* destaca por mayor inmediatez relativa (11,03% en 1h-24h y 53,09% en 1-7 días), mientras *Education and Reference* concentra más cierres tardíos (24,58% en más de 30 días). Este resultado complementa ***Q21***.

10.CONCLUSIONES

El desarrollo de este proyecto ha demostrado la viabilidad de procesar de manera eficiente un archivo XML masivo de 11,42 GB mediante técnicas de lectura incremental, logrando extraer un subconjunto manejable de 613.245 registros. Además, la verificación cuantitativa mediante *XQuery* ha sido fundamental para revelar inconsistencias entre la documentación oficial del *dataset* y la realidad de los datos, como la ausencia de campos teóricamente obligatorios, lo que permitió diseñar un esquema XSD mucho más preciso y realista.

Por otro lado, el análisis de la red social evidenció una clara separación de roles en la plataforma, donde los usuarios que preguntan rara vez responden, recayendo la mayor parte de las soluciones en un grupo reducido de "especialistas" hiperactivos. Asimismo, se observó que la naturaleza de la categoría define el comportamiento: los temas subjetivos como Ciencias Sociales generan más debate y se resuelven de forma rápida en una media de 14,46 días, mientras que los temas objetivos como Educación o Ciencias exactas tardan semanas en obtener una respuesta definitiva (47,98 días de media) validada por la comunidad.

Finalmente, aunque la integridad referencial de los registros resultó ser excelente, el análisis temporal desveló discontinuidades importantes en 2006 y picos anómalos de actividad, indicando que el corpus analizado refleja extracciones parciales de datos más que un crecimiento orgánico y continuo de la plataforma

11.BIBLIOGRAFÍA

[1] Yahoo! Research. (2007). Yahoo! Answers Comprehensive Questions and Answers Dataset (FullOct2007). Yahoo! Labs.

[2] Shen, H.; Li, Z.; Liu, J.; Grant, J.E. (2013). Knowledge Sharing in the Online Social Network of Yahoo! Answers and Its Implications. IEEE Transactions on Computers.

[3] BaseX Team. (2024). BaseX Documentation. https://docs.basex.org. Último acceso marzo de 2026.